

Análisis de Equidad en Modelos Predictivos: Disparidad de Falsos Positivos Demográficos en la Predicción de Riesgo Cardiovascular Mediante Modelos Tabulares

Daniel Alemán Ruiz, Sebastián Rodríguez Sánchez, Lindsay Marín Sánchez

Escuela de Ingeniería en Computación, Instituto Tecnológico de Costa Rica

Cartago, Costa Rica

IC-6200 – Inteligencia Artificial · Prof. Kenneth Obando Rodríguez · Proyecto: Primera Etapa · II Semestre 2026 · 1 de setiembre del 2026

Resumen (Preliminar)—Este trabajo es un estado del arte sobre el aprendizaje automático clásico, que investiga el problema de la capacidad de discriminación de diferentes modelos tabulares y la amplificación o reducción de sesgos hacia subgrupos por sexo, raza e ingreso monetario. Se trabaja con el dataset de BRFSS 2024 ($N = 457,670$). Se recopilan varias fuentes, entre ellas artículos, extractos de libros u otros surveys para generar un baseline sobre el que se rige este trabajo. De este se obtiene que las métricas más relevantes para el estudio son Area Under the ROC Curve (AUROC), False Positive Rate (FPR), Equalized Odds Difference (EOD) y calibración por grupo. Para realizar la comparación, se escogieron modelos de Machine Learning comúnmente utilizados en el área, incluyendo Random Forest, XGBoost, Regresión Logística y SVM lineal. La meta es alcanzar o superar un resultado de entre 0.751 y 0.771 AUROC en todos los modelos, reducir la diferencia de Falsos Positivos entre poblaciones, disminuir o igualar el Equalized Odds Difference (EOD) al rango de 0.131 a 0.136, y acercar el valor de calibración por grupo a 1. Para ello, se implementa una metodología que asegura el balance de los datos para la evaluación justa y la prevención de data leakage. Esta consiste en aplicar una limpieza y selección de columnas sobre el dataset, normalizar datos mediante MinMax Scaling, validación estratificada cruzada de cinco pliegues, imputación proporcional y *Synthetic Minority Over-sampling Technique* (SMOTE). En resumen, este survey busca ser un marco comparativo para entender la parcialidad que existe hacia determinados grupos demográficos entre los distintos modelos de Machine Learning.

Palabras Clave—Predicción de enfermedades cardiovasculares · Sesgos en modelos de machine learning · CVD · AUROC · EOD · FPR · Falsos positivos · Calibración por grupo · Machine Learning · Random Forest · XGBoost · LightGBM · SVM lineal · SMOTE

I. INTRODUCCIÓN

La incorporación de aprendizaje automático en la predicción de riesgo cardiovascular ha demostrado ganancias consistentes de desempeño frente a las líneas base clínicas tradicionales,

pero esa ganancia no está distribuida de forma pareja entre la población: la literatura de equidad algorítmica en salud documenta casos en los que los mismos modelos que mejoran la discriminación global subestiman sistemáticamente el riesgo en subgrupos demográficos específicos. Este proyecto aborda dicho problema sobre un dataset poco explorado por esa literatura, la cual se concentra mayoritariamente en registros médicos hospitalarios: el *Behavioral Risk Factor Surveillance System* (BRFSS) 2024 del CDC, una encuesta poblacional autorreportada con un desbalance de clases considerable.

La pregunta de investigación que guía este trabajo es: ¿qué relación existe entre la capacidad de discriminación de diferentes modelos tabulares y la amplificación o reducción de sesgos (FPR y EOD) hacia subgrupos protegidos por sexo, raza e ingreso? Para responderla, se comparan cuatro modelos bajo un mismo pipeline, evaluando tanto su desempeño general como métricas específicas de equidad, con especial atención al manejo del desbalance de clases y a la calidad de los datos disponibles.

Como hipótesis de trabajo, se plantea que los modelos con mayor capacidad de discriminación (los ensambles Random Forest y XGBoost) presentarán una disparidad de FPR y EOD mayor entre grupos protegidos que un modelo lineal simple (Regresión Logística), replicando el patrón reportado en la literatura para otros datasets clínicos [1]. Esta hipótesis es falsable: si los modelos complejos no muestran una disparidad mayor, o la muestran menor, la hipótesis queda refutada.

A partir de esto, el objetivo general del proyecto es comparar el desempeño predictivo y la equidad entre modelos tabulares para la predicción de riesgo cardiovascular sobre BRFSS 2024. Los objetivos específicos son: (1) construir un pipeline de preprocesamiento sin fuga de datos para el dataset, (2) entrenar y comparar cuatro modelos (Regresión Logística,

Random Forest, XGBoost y SVM) bajo el mismo protocolo experimental, (3) cuantificar la disparidad de FPR y EOD entre grupos de sexo, raza e ingreso para cada modelo, y (4) contrastar los resultados obtenidos contra el baseline de literatura definido en la Sección III.

El resto del documento se organiza de la siguiente forma: la Sección II revisa los trabajos relacionados en tres ejes (equidad algorítmica en salud, técnicas tabulares para riesgo cardiovascular, y estudios previos sobre BRFS), la Sección III establece el baseline de literatura, la Sección IV describe la metodología propuesta, la Sección V presenta el análisis técnico del dataset, y las Secciones VI y VII cierran con las consideraciones éticas y la declaración de uso de IA.

II. TRABAJOS RELACIONADOS

II-A. Eje A (El Problema)

II-A1. Evolución del problema y factores de riesgo: El uso de inteligencia artificial (IA) en el ámbito médico ha crecido de forma acelerada, pasando de sistemas basados en reglas a modelos de aprendizaje automático y aprendizaje profundo aplicados a imágenes médicas, predicción de riesgo y apoyo a la decisión clínica. Zhang y Zhang [2] identifican cinco factores que determinan la confiabilidad de la IA médica (calidad de los datos, sesgo algorítmico, opacidad, seguridad y atribución de responsabilidad), y distinguen dentro del sesgo algorítmico dos orígenes: el inducido por decisiones humanas de diseño (etiquetado, ponderación de atributos) y el inducido por datos de entrenamiento no representativos de la población objetivo, este último ilustrado con el caso de sistemas de diagnóstico dermatológico que fallan en pieles oscuras por su escasa representación en las bases de imágenes disponibles.

II-A2. Fuentes documentadas de sesgo algorítmico en salud: La evidencia empírica reciente confirma que el sesgo algorítmico en salud es un patrón medible en al menos tres frentes distintos. Obra et al. [3] revisaron 690 instrumentos de decisión clínica y encontraron una sobrerrepresentación sistemática de participantes e investigadores blancos y varones en su desarrollo. Abulibdeh et al. [4] muestran que, al clasificar raza a partir de texto clínico, los modelos basados en transformadores presentan tasas de verdaderos positivos cercanas a cero para grupos minoritarios, mientras que una arquitectura alineada con la estructura de la nota clínica reduce sustancialmente esa disparidad, evidenciando que el sesgo también depende de decisiones arquitectónicas y no solo de los datos. No todos los hallazgos son negativos: Hourmouzi et al.

[5] evaluaron cuatro algoritmos para detección de amiloidosis cardíaca y el de mejor desempeño cumplió el criterio de igualdad de oportunidades entre pacientes de raza negra, sugiriendo que el sesgo no es inevitable cuando se audita explícitamente.




Figura 1. Taxonomía de fuentes de sesgo algorítmico en salud según la etapa del ciclo de vida del modelo (recolección de datos, definición de variables, arquitectura/entrenamiento, despliegue). El recuadro punteado ilustra un caso donde la auditoría explícita de equidad evitó el sesgo, en contraste con la ausencia de auditoría documentada en la etapa de despliegue.

II-A3. Marcos y esfuerzos de mitigación a nivel de dominio: A nivel de dominio se han propuesto marcos para anticipar el sesgo antes del despliegue clínico. Agarwal et al. [6] proponen un marco técnico de cuatro etapas, citando el caso ampliamente documentado de un algoritmo que usaba el costo de atención como proxy de necesidad de salud y subestimaba sistemáticamente la enfermedad en pacientes negros. Zhang y Zhang [2] plantean, en cambio, un marco de gobernanza en tres niveles (valores, principios y normas éticas) orientado a la regulación. A nivel técnico, Abulibdeh et al. [4] muestran que intervenciones de mitigación (muestreo estratificado, pérdida consciente de equidad, ajuste de umbrales) no tienen un efecto uniforme entre arquitecturas, mejorando la paridad en unas y degradando el desempeño en otras.

II-A4. Qué está resuelto y qué sigue abierto: Pese a estos avances, la adopción sistemática de principios de equidad en estudios clínicos sigue siendo escasa. Huang et al. [7] revisaron 12 estudios de sesgo racial en ML clínico: el 67 % confirmó sesgo, pero solo el 17 % evaluó mitigación con comparación contra un modelo base, lo que atribuyen a la escasa disponibilidad de datos y al reporte deficiente de los modelos. Esta brecha se extiende más allá del aprendizaje supervisado: Adouani et al. [8] muestran que la equidad en aprendizaje no supervisado en salud carece de definiciones y métricas consensuadas. En conjunto, la evaluación sistemática

de equidad mediante métricas explícitas, el enfoque que este proyecto adopta para BRFSS 2024, sigue siendo la excepción y no la norma en la literatura clínica.

II-B. Eje B: Las Técnicas

II-B1. Estado actual de los métodos y sus fortalezas: En el ámbito de la predicción de riesgo cardiovascular mediante registros médicos electrónicos (EHR), el estándar empírico actual ha transitado de los modelos estadísticos tradicionales hacia los algoritmos de aprendizaje automático clásico o “tabular”, destacando los métodos de ensamblaje basados en árboles (Random Forest, XGBoost, LightGBM) y las Máquinas de Vectores de Soporte (SVM) [1], [9]. La fortaleza principal de estas técnicas radica en su capacidad para ingerir datos estructurados de alta dimensionalidad y capturar fenotipos cardiovasculares complejos sin requerir la especificación manual de términos de interacción [10]. Mientras que la regresión logística clásica asume una relación log-lineal restrictiva, algoritmos como Random Forest reducen la varianza mediante remuestreo (*bagging*), y arquitecturas como XGBoost manejan de forma nativa la ausencia masiva de datos clínicos sin depender de imputaciones artificiales [1]. La evidencia empírica confirma que estos ensamblajes incrementan consistentemente la capacidad de discriminación (AUROC) frente a las líneas base clínicas tradicionales [11].

II-B2. Supuestos operativos y limitaciones técnicas: A pesar de su superioridad predictiva, la literatura advierte sobre límites matemáticos y supuestos operativos severos al implementar estas técnicas en la salud pública. El primer supuesto crítico es que estos modelos operan bajo el principio de Minimización del Riesgo Empírico (ERM), optimizando sus fronteras de decisión para reducir el error promedio sobre el conjunto de datos global [12]. Esta mecánica asume implícitamente que los datos son representativos, lo cual constituye su mayor limitación: al ser intrínsecamente agnósticos a los mecanismos sociológicos, los algoritmos tabulares absorben el ruido estructural y subestiman sistemáticamente el riesgo en subpoblaciones marginadas, amplificando la disparidad demográfica [13]. Esta brecha no se limita a Estados Unidos: el estudio LASI en India [14] documenta un patrón similar en función de casta y nivel socioeconómico.

II-B3. La paradoja de la equidad y la calibración: Finalmente, un límite documentado en las arquitecturas tabulares contemporáneas es la incompatibilidad matemática entre la optimización de equidad grupal y la utilidad clínica [10].

Intentar mitigar las disparidades de los modelos de ensamblaje alterando su función de pérdida para forzar métricas como los Odds Igualados provoca una descalibración patológica de las probabilidades predichas [10]. Dado que las guías cardiológicas prescriben tratamientos basados en umbrales de riesgo absoluto estrictos, la literatura concluye que modificar paramétricamente estos algoritmos tabulares durante su entrenamiento deteriora la precisión global (fenómeno de “nivelación hacia abajo”) y resulta incompatible con la seguridad clínica del paciente [10], [12].

II-C. Eje C (El Dataset)

El dataset empleado es el BRFSS (Behavioral Risk Factor Surveillance System) 2024, con 457,670 filas y 301 columnas. Los datos provienen de una encuesta anual de salud pública en Estados Unidos realizada por el CDC (Centers for Disease Control and Prevention).

Se revisaron cinco artículos relevantes para el dataset utilizado, de ellos tres usan el mismo dataset de BRFSS [15], [16], [17] únicamente variando el año (2022, 2024 y 2024 respectivamente). Los demás tratan los datasets *Cardiovascular Disease dataset de Kaggle* [18], y un conjunto de cohortes combinadas actualizado, que incluye seis estudios de investigación cardiovascular (ARIC, CARDIA, CHS, FHS Offspring, MESA y JHS) [1].

Los artículos que comparten el mismo dataset de esta investigación no son directamente comparables, tienen diferencias importantes. Para empezar, el BRFSS 2022 [15], varía en el número de registros, con solo 221,643 participantes. En cuanto al paper de investigación [17], su foco es la detección del VIH. A pesar de esto, se agrega porque aborda temas de salud pública sobre la misma población y lleva a conclusiones sobre la discriminación de los modelos de *Machine Learning*. Por último, ninguno de los artículos coincide con el número de columnas previsto para esta investigación, ya que omiten o no mencionan el uso de preprocesamiento para la limpieza de valores innecesarios.

Las publicaciones que difieren en datos tienen una clara limitación sobre la precisión de los valores obtenidos. El dataset de Kaggle [18] carece de características demográficas que permiten el cálculo de falsos positivos sobre el sexo y la raza, pero comparte columnas con el dataset seleccionado. Por el contrario, el conjunto de cohortes dado por [1] resulta pertinente por la inclusión de métricas de EOD (*Equal Op-*

portunity Difference), además de que trata con la predicción de riesgo cardiovascular.

Al revisar los resultados de estas investigaciones, se puede extraer los mejores resultados encontrados. El paper [15] obtiene su AUC más alto al manejar técnicas SMOTE. XGBoost consigue 0.94 AUC, seguido de Random Forest con 0.87 de AUC. Además, encuentra que las características a las que se dieron más importancia fueron: Sexo masculino, edad superior a los 65 años, diagnóstico de diabetes, enfermedades renales, situación laboral y aislamiento social. Después, se tiene que [16] alcanza el mejor rendimiento usando LightGBM con 0.8541 AUC. A su vez, obtuvo un FPR de 0.0108, sin embargo, al utilizar datos no balanceados, el modelo detecta una gran cantidad de *False Negatives*. [18] se centra en los beneficios de aplicar SMOTE para el balanceo de datos. Al utilizarlo, el resultado más alto que presenta el estudio es 0.982 AUC con Stacking Ensemble, seguido de 0.878 AUC con Random Forest.

Otras conclusiones pertinentes son las vinculadas a la equidad del modelo. La investigación [17] encuentra un rango DPD de 0.154–0.169 y EOD de 0.565–0.669 entre todos los modelos probados. Indica que el valor de EOD es cinco veces más alto de lo aceptable. También, muestra que al aplicar métodos fairness-aware al dataset, es posible una reducción sustancial del DPD hasta 0.029–0.054 sin perjudicar Accuracy. Mientras tanto, el estudio de [1] expone un EOD promedio de 0.001 a 0.018 al comparar grupos raciales y 0.131 a 0.136 entre género masculino y femenino.

De lo anterior, se extrae que Stacking Ensemble fue el modelo más preciso con 0.982 AUC. Random Forest ha sido el más consistente entre las distintas literaturas, posicionándose en segundo lugar en varios artículos. [1] tiene una métrica ideal de EOD con 0.001–0.018 cuando se trata con grupos raciales, sin embargo, solo compara población blanca y negra. En cuanto a EOD entre sexo masculino y femenino, 0.131 a 0.136 es el número más bajo que se logró conseguir.

Las principales debilidades del dataset BRFSS 2024 es el desbalance de grupos demográficos, y la baja representación de determinadas poblaciones debido a la naturaleza del dataset como encuesta telefónica. A su vez, hay una gran cantidad de datos faltantes o inconsistentes producto del autorreporte de los entrevistados.

II-D. Tabla Comparativa

Tabla I
COMPARATIVA DE ARTÍCULOS RELACIONADOS

Ref.	Año	Técnica	Dataset / Cohorte	Métrica Principal	Mejor Resultado	Limitación
Zhang y Zhang [2]	2023	Marco conceptual: taxonomía de sesgo y gobernanza	N/A (marco teórico)	N/A	5 factores de confiabilidad; gobernanza en 3 niveles	Sin validación empírica sobre un dataset propio
Obra et al. [3]	2025	Revisión sistemática de instrumentos clínicos	690 instrumentos de decisión clínica	Representatividad demográfica	Sobrerrepresentación de participantes/investigadores blancos y varones	No cuantifica el impacto en el desempeño de los modelos
Abulibdeh et al. [4]	2026	Transformers para NLP clínico con <i>fairness-awareness</i>	Texto clínico (notas)	TPR por grupo racial	Arquitectura alineada a la nota clínica reduce disparidad de TPR	Mitigación no uniforme entre arquitecturas
Hourmozdi et al. [5]	2025	4 modelos predictivos (detección de amiloidosis)	Pacientes evaluados por amiloidosis cardíaca	Igualdad de Oportunidades	Mejor modelo cumplió igualdad de oportunidades para raza negra	Resultado positivo no generalizable a otros contextos
Agarwal et al. [6]	2023	Marco técnico de mitigación de sesgo en 4 etapas	Caso: proxy de costo de atención	N/A	Marco para anticipar sesgo antes del despliegue clínico	Basado en casos documentados, sin validación cuantitativa propia
Huang et al. [7]	2022	Revisión sistemática (<i>scoping review</i>)	12 estudios de sesgo racial en ML clínico	% de estudios con mitigación evaluada	67 % confirmó sesgo; solo 17 % evaluó mitigación con modelo base	Escasa disponibilidad de datos y reporte deficiente
Adouani et al. [8]	2026	Survey	Aprendizaje no supervisado en salud	N/A (sin métricas consensuadas)	Identifica ausencia de definiciones y métricas de equidad consensuadas	Área emergente sin marco de evaluación estandarizado
Li et al. [1]	2023	RF, XGBoost, LR, PCE	VUMC EHR ($N = 109\,490$)	AUC, EOD, DI	RF AUC: 0.771 (PCE: 0.730)	Mitigación estándar degrada precisión general.
Davoudi et al. [9]	2024	LightGBM, XGBoost, AutoGluon	VNS Health ($N = 12\,189$)	AUC, Equal Opportunity	Ensamble AUC: 0.89	Disparidad severa en subgrupos interseccionales.
Foryciarz et al. [10]	2022	PCE (LR), modelos restringidos	ARIC y cohortes agrupadas	Calibración (7.5 %), FPR, FNR	Unconstrained AUC: ~0.76	Forzar Equalized Odds destruye la calibración clínica.
Cho et al. [11]	2021	LR, RF, AdaBoost, NN	Cohorte Corea ($N = 222\,998$)	C-Statistic (AUROC)	Modelos tabulares AUC: 0.751	Cohorte homogénea sin validación externa diversa.
Pfohl et al. [12]	2021	LR, Árboles de Decisión	Múltiples EHR observacionales	AUROC disp., Calibración, MAE	Modelos sin restricciones óptimos	Leveling down: paridad degrada precisión global.
Pfohl et al. [13]	2022	ERM, DRO, Submuestreo	3 bases de datos EHR independientes	Worst-case AUROC, AUPRC	ERM baseline AUC > 0.82	Ruido en etiquetas y bajo tamaño muestral efectivo.
Lee et al. [14]	2025	RF, XGBoost, LightGBM, LR	Cohorte LASI ($N > 55\,000$)	AUROC, Precisión, EOD	LightGBM / GBT AUC: 0.80	Brechas persistentes en castas y bajo nivel socioeconómico.
Imani et al. [15]	2026	XGBoost, RF, Logistic Regression, Naive Bayes	BRFSS 2022 ($N = 221,643$)	Accuracy, AUROC, F1-Score, Sensitivity	XGBoost: 0.94 % AUROC	Disparidad significativa según grupo sociodemográfico.
Islam et al. [16]	2026	Dual-branch FT-Transformer architecture	BRFSS 2024 ($N > 450,000$)	F1-Score, Sensitivity, FNR	Disminución del 50 % en FNR	Falta de validación en datasets clínicos externos.
Farquhar [17]	2026	Logistic Regression, RF, Gradient Boost, XGBoost	BRFSS 2024 ($N = 386,775$)	DPD, EOD	DPD de 0.029–0.054 y EOD 0.565–0.669 entre todos los modelos.	Subrepresentación de poblaciones sin acceso estable a teléfono en el dataset.
Dritsas & Triga [18]	2023	SVM, Gradient Boosting, RF, NB, Logistic Regression, Stacking ensemble.	Cardiovascular Disease Dataset en Kaggle	Accuracy, Sensitivity, Precision, AUC	Stacking ensemble AUC: 98,2 %	Falta de características adicionales relevantes
Sathyaseelan & Sarathambekai [19]	2025	Logistic Regression, Naïve Bayes, RF, KNN, Árboles de Decisión, SVM, XGBoost, LightGBM	Cardiovascular Disease Dataset en Kaggle	Accuracy	Accuracy con SMOTE LightGBM: 96.72 %	Tamaño de dataset relativamente pequeño.
Sheetal et al. [20]	2025	SVC, Árboles de Decisión, RF, KNN, Neural Network	Framingham Heart Study dataset	Accuracy, Precision, Sensitivity, F1-Score	RF: 91 % Accuracy	Mal rendimiento en la predicción de clases minoritarias por el desbalance de datos.
Wang et al. [21]	2025	Survey	Survey	AUC	Neural Network: 0.87 AUC	Falta de pruebas en entornos externos y clínicos en los modelos actuales.
Liu et al. [22]	2025	Survey	NHIS-HEALS	AUC	RF: 0.865 (95 % CI: 0.812–0.917) AUC	Dificultad de comparación directa entre todos los estudios por conjuntos de variables, hiperparámetros y software distinto.
Rawash et al. [23]	2026	RF, XGBoost, KNN, GaussianNB	Framingham Heart Disease, Cleveland Heart Disease	Accuracy, Sensitivity, Precision, AUC, F1-Score, Specificity	XGBoost: 97.39 % AUC	Falta de explicabilidad sobre las decisiones que toma el modelo.

II-E. Brechas de Literatura

De la revisión anterior se identifican cinco carencias concretas en la literatura, de las cuales este proyecto aborda directamente cuatro y reconoce una fuera de su alcance.

1. La evaluación sistemática de equidad sigue siendo la excepción. Como se señaló en la Sección II-A, la mayoría de los trabajos que documentan sesgo algorítmico en salud lo hacen mediante revisiones cualitativas o marcos conceptuales ([2], [3], [6], [7]), sin acompañarlos de métricas de equidad cuantitativas sobre un dataset propio. Este proyecto lo aborda directamente: mide FPR, EOD y calibración de forma explícita y reproducible sobre BRFS 2024.

2. Los estudios de equidad rara vez cubren más de un atributo protegido a la vez. La mayoría de los trabajos revisados evalúa disparidad por raza o por sexo, pero no ambos junto con una tercera dimensión socioeconómica. El propio análisis exploratorio de este proyecto (Sección V-A) encontró que el gradiente de riesgo por nivel de ingreso (19.87 % a 5.51 %) es más pronunciado que las brechas de sexo o raza, algo que ningún estudio revisado reporta para este tipo de problema. Este proyecto lo aborda directamente, incluyendo `_INCOMG1` como atributo protegido adicional.

3. Casi no hay literatura de equidad sobre datos de encuesta autorreportada como BRFS. De los cinco artículos revisados sobre el mismo dataset o datasets análogos (Sección II-C), solo tres usan BRFS, y ninguno combina un modelo lineal interpretable (Regresión Logística o SVM lineal) con ensambles de árboles bajo un mismo protocolo de equidad. Este proyecto lo aborda directamente al comparar los cuatro modelos definidos en la Sección IV-E sobre el mismo pipeline.

4. La paradoja entre equidad y calibración no se ha probado con alternativas más simples. Foryciarz et al. [10] y Pfohl et al. [12] muestran que forzar paridad de *Equalized Odds* durante el entrenamiento degrada la calibración clínica (fenómeno de “nivelación hacia abajo”), pero no evalúan si técnicas más simples de balanceo, como *class weighting* (Sección IV-D), logran una mejora de equidad sin ese costo. Este proyecto lo aborda de forma parcial: compara el desempeño y la equidad de los cuatro modelos entrenados con SMOTE, pero implementar y comparar técnicas de mitigación restringida (como *Equalized Odds* forzado durante el entrenamiento) queda fuera del alcance de esta etapa.

5. Los datasets más usados en la literatura de CVD ca-

recen de variables demográficas. El dataset de Kaggle usado por Dritsas y Trigka [18] y por Sathyaseelan y Sarathambekai [19] alcanza resultados altos de AUC (hasta 0.982), pero no incluye sexo, raza ni ingreso, por lo que no permite evaluar equidad. Esta limitación no es algo que este proyecto pueda corregir sobre esos datasets ajenos, pero explica por qué se optó por BRFS a pesar de ser un dataset menos explorado en la literatura de *Machine Learning* clásico: es, de los revisados, el único con la cobertura demográfica necesaria para responder la pregunta de investigación de este trabajo.

III. BASELINE DE LITERATURA

Con base en la revisión de literatura sobre modelos tabulares aplicados a datos cardiovasculares, se establece como meta principal alcanzar o superar un área bajo la curva ROC (AUROC) entre **0.751 y 0.771** [1], [11]. Este rango corresponde a los resultados reportados por Cho et al. (2021) y Li et al. (2023) al evaluar ensamblajes como Random Forest y Gradient Boosting sobre registros clínicos.

De forma complementaria, como línea base de la evaluación de imparcialidad de los algoritmos, se busca reducir la disparidad en la tasa de falsos positivos y disminuir o igualar la Diferencia de Odds Igualadas (*Equalized Odds Difference*, EOD) al rango de 0.131 a 0.136 entre hombres y mujeres. Esta meta toma como referencia a Li et al. (2023) [1], quienes reportan ese rango de EOD al comparar Random Forest frente a regresión logística por sexo.

Es importante señalar que esta comparación no es perfecta. Li et al. y Cho et al. usan registros clínicos electrónicos (EHR) de hospitales, mientras que este proyecto usa BRFS, una encuesta telefónica autorreportada. Esto implica diferentes fuentes de error (recuerdo del paciente en vez de diagnóstico clínico) y poblaciones distintas (EE. UU. institucional vs. cohorte coreana). Por lo tanto, el rango de AUROC se toma como una referencia razonable del estado del arte y no como un objetivo exacto bajo el mismo protocolo.

IV. METODOLOGÍA PROPUESTA

IV-A. Definición del Problema

Este proyecto se plantea como un problema de clasificación binaria supervisada para encontrar sesgos según grupos demográficos. La variable objetivo, a la que llamamos riesgo cardiovascular, toma el valor de 1 si la persona encuestada reporta haber tenido un infarto, una enfermedad coronaria o un accidente cerebrovascular, y el valor de 0 si no reporta

ninguno de los tres. Esta variable se construye a partir de las columnas CVDINFR4, CVDCRHD4 y CVDSTRK3 del dataset BRFSS.

Como variables de entrada se usan datos demográficos (edad, sexo, raza), datos antropométricos (índice de masa corporal, peso, altura), hábitos de vida (fumado, actividad física, consumo de alcohol) y otras condiciones de salud relacionadas (diabetes, salud general percibida). El sexo y la raza se usan además como atributos protegidos: aparte de ser posibles variables de entrada, sirven para comparar si el modelo se equivoca más con unos grupos que con otros.

En resumen, el modelo debe predecir si una persona tiene riesgo cardiovascular a partir de estas variables, y al mismo tiempo se debe revisar si la tasa de error se mantiene parecida entre los grupos demográficos mencionados.

IV-B. Origen de los datos

Para esta investigación, se utiliza el dataset *Behavioral Risk Factor Surveillance System* (BRFSS) de 2024. Este obtiene sus datos de una encuesta anual de salud pública realizada por el CDC (Centers for Disease Control and Prevention). Cubre 50 estados, el Distrito de Columbia, Guam, Puerto Rico y las Islas Vírgenes de los Estados Unidos. Incluye datos demográficos, información biométrica, hábitos, condiciones médicas, acceso a salud, entre otros aspectos que permiten monitorear el estado de la población.

Este dataset originalmente contiene 457,670 filas y 301 columnas. Para el estudio se selecciona un subconjunto de variables vitales para la predicción de riesgo cardiovascular y análisis de equidad/disparidad demográfica. Según [19], la precisión y eficiencia de un modelo depende de la selección de características relevantes, incluir variables con poca relación causa sobreajuste, complejidad computacional innecesaria y menor precisión. Por este motivo, se eliminan columnas para el cálculo de valores intermedios, información sobre acceso a salud o datos familiares.

IV-C. Pipeline de Preprocesamiento

El pipeline de preprocesamiento se descompone en seis etapas: Limpieza del dataset crudo y selección de columnas necesarias, conversión estándar de medidas, división del dataset en pliegues, imputación proporcional, normalización de datos mediante *MinMax Scaling* y SMOTE (*Synthetic Minority Over-sampling Technique*). La Figura 2 resume este proceso.




Figura 2. Pipeline de preprocesamiento y entrenamiento. Los pasos dentro del recuadro punteado se repiten de forma independiente para cada uno de los 5 pliegues, usando solo los datos de entrenamiento de ese pliegue, para evitar la fuga de datos.

En la primera fase, se usará la herramienta Pandas para transformar el dataset. El enfoque será convertir los valores en la encuesta catalogados como (no sabe/rechazó responder), frecuentemente representados con un número del siete al nueve, a vacío. Asimismo, se realiza una conversión de pies a centímetros para la altura y de libras a kilogramos para el peso. Estos valores están escritos de forma no continua, pues el peso suma 9000 a la cantidad base cuando el número ya está en centímetros o kilogramos respectivamente. Este cambio resulta vital para modelos basados en distancias como SVM. Las transformaciones mencionadas no implican un riesgo sobre filtración de datos, así que se realizan antes de las particiones.

El siguiente paso es la partición del dataset usando validación cruzada estratificada (Stratified K-Fold con 5 pliegues). La cantidad 5 es estándar en múltiples artículos [19] [20] [21], y se utiliza para este estudio. A su vez, esta es una de las técnicas más comunes de validación. De acuerdo con un survey de modelos de predicción basados en Machine Learning para el riesgo de enfermedad cardiovascular [22], para la validación, 80.95 % utilizaron N-Fold Cross Validation, y dividieron el dataset entre pliegues de entrenamiento y prueba.

Una vez se divide el dataset en pliegues, se busca aplicar imputación proporcional para cubrir los valores nulos presentes en el dataset. Esta técnica se ajustará según los valores existentes en cada partición del dataset, previniendo filtración de datos y asegurando que los valores utilizados reflejen la media de la población.

A continuación, se implementa una normalización con Min-Max Scaling a las atributos cuantitativos en una escala de 0 a 1, a nivel de partición. Nuevamente, hacerlo en esta etapa es esencial para prevenir filtración de datos con la información del dataset global. La normalización tiene el objetivo de hacer

que el modelo juzgue equitativamente y evite preferencia sobre alguna columna específica por la magnitud de sus entradas. [23]

IV-D. Manejo de Desbalance

El análisis exploratorio inicial reveló que el dataset presenta un desbalance considerable entre clases: 88.18 % de los registros corresponden a ausencia de riesgo cardiovascular, frente a 11.82 % con presencia de riesgo (definido como historial de infarto, enfermedad coronaria, o ACV). Este desbalance se mantiene de forma similar entre géneros (13.57 % en hombres vs. 10.24 % en mujeres), pero varía de forma más notable entre grupos raciales (entre 4.39 % y 14.05 % según el grupo), lo cual es relevante para el análisis de equidad del presente estudio. La Figura 3 muestra este porcentaje desglosado por género y por grupo racial. Dado este desbalance, se aplicará SMOTE para el balanceo de los registros.




Figura 3. Porcentaje de registros con riesgo cardiovascular por género y por grupo racial, con el promedio general del dataset como referencia.

Antes de elegir SMOTE se consideraron otras dos formas de manejar el desbalance, siguiendo comparaciones reportadas para este mismo tipo de problema [20]. La primera es asignar un peso mayor a la clase minoritaria durante el entrenamiento (*class weighting*), de modo que el modelo penalice más los errores sobre esa clase sin generar datos nuevos. La segunda es el submuestreo (*undersampling*), que reduce la cantidad de registros de la clase mayoritaria hasta igualarla con la minoritaria. La Tabla II resume las ventajas y desventajas de cada técnica.

Tabla II
COMPARACIÓN DE TÉCNICAS PARA EL DESBALANCE DE CLASES

Técnica	Ventaja	Desventaja
SMOTE	Genera ejemplos sintéticos sin descartar datos reales	Puede crear ejemplos poco realistas si hay muy pocos datos en el grupo minoritario
Class weighting	No modifica los datos, solo el entrenamiento	No siempre corrige bien un desbalance muy extremo
Undersampling	Simple y rápido de aplicar	Descarta información real de la clase mayoritaria

Se eligió SMOTE porque, a diferencia del submuestreo, no descarta información real del dataset (que ya es limitado para la clase minoritaria), y porque genera ejemplos sintéticos en vez de solo repetir registros existentes, lo cual reduce el riesgo de sobreajuste frente a un sobremuestreo simple. El uso de *class weighting* queda como una alternativa a probar de forma exploratoria durante la experimentación, comparando su efecto sobre las métricas de equidad definidas en la Sección IV-F contra el de SMOTE.

IV-E. Estrategia de Modelado

Según la revisión de la literatura presentada en la Sección II-B, los modelos tabulares que consistentemente reportan mejor desempeño para la predicción de riesgo cardiovascular sobre datos de encuestas o registros clínicos son los ensamblajes basados en árboles, en particular Random Forest y XGBoost [1], [9], [14]. Por esta razón, estos dos algoritmos serán los modelos principales a evaluar en este proyecto.

Como línea base interpretable se incluye además Regresión Logística (LR), siguiendo el mismo enfoque de comparación usado en varios de los trabajos revisados [10], [12], [13], donde un modelo lineal simple sirve de referencia para medir qué tanto aportan los modelos más complejos, tanto en desempeño como en equidad entre grupos.

Se incluye además una Máquina de Vectores de Soporte (SVM), otra técnica clásica destacada en la Sección II-B para este dominio [1], [9]. A diferencia de los árboles de decisión, SVM es sensible a la escala de las variables, lo cual justifica la normalización aplicada en el pipeline (Sección IV-C). Teniendo en cuenta la cantidad de datos, se optará por un kernel lineal o una solución escalable como *LinearSVC* para mantener los tiempos de entrenamiento bajo control.

Los cuatro modelos (LR, Random Forest, XGBoost y SVM) se entrenarán y evaluarán bajo el mismo pipeline y las mismas métricas descritas en esta sección, y se compararán entre sí tanto en AUROC como en las métricas de equidad definidas más adelante. El objetivo no es solo identificar el modelo con mejor desempeño general, sino observar si los modelos más complejos, que suelen ganar en AUROC, también mantienen (o empeoran) la disparidad entre grupos demográficos frente al modelo lineal simple, tal como reportan Li et al. [1] al comparar Random Forest contra regresión logística.

IV-F. Métricas de Evaluación

Para medir qué tan bien funciona el modelo en general, se usará el área bajo la curva ROC (AUROC). Esta métrica indica qué tan bien el modelo distingue entre personas con y sin riesgo cardiovascular, sin depender de un único umbral de decisión. Se eligió como métrica principal porque es la misma que reportan la mayoría de los trabajos revisados en la Sección II, lo que permite comparar los resultados de este proyecto contra la literatura (ver Sección III).

$$AUROC = \int_0^1 TPR(FPR) d(FPR)$$

Donde:

- TPR: Tasa de verdaderos positivos.
- FPR: Tasa de falsos positivos.

Para medir la equidad del modelo entre grupos demográficos (sexo y raza) se usarán tres métricas adicionales:

- **Diferencia de Odds Igualadas (*Equalized Odds Difference*, EOD):** diferencia en la tasa de verdaderos positivos entre grupos. Un valor cercano a 0 indica que el modelo detecta el riesgo real con una efectividad parecida en todos los grupos.

$$EOD = \max_{i,j} |TPR_i - TPR_j|$$

Donde:

- TPR: Tasa de verdaderos positivos.

La definición completa de *Equalized Odds* exige paridad tanto en TPR como en FPR entre grupos. En este trabajo, esa segunda condición se evalúa por separado mediante la métrica de disparidad de FPR descrita a continuación, en vez de combinarla en una sola fórmula; de forma conjunta, ambas métricas cubren el mismo criterio.

- **Disparidad en la tasa de falsos positivos (FPR):** diferencia en la proporción de personas sin riesgo real que el

modelo clasifica por error como en riesgo, comparando entre grupos.

$$FPR = \frac{FP}{FP + TN}$$

Donde:

- FP: Número de falsos positivos.
- TN: Número de verdaderos negativos.
- **Calibración por grupo:** si el modelo predice, por ejemplo, un 20 % de probabilidad de riesgo, se revisa que cerca del 20 % de las personas de ese grupo con esa predicción sí tengan riesgo real. Se busca un valor cercano al 1. Una cantidad menor señala que el modelo predijo menos casos de los que realmente ocurrieron. Por el contrario, un número alto significa que se subestima el riesgo de un grupo específico.

$$Calibracion_G = \frac{\sum_{i \in G} \hat{p}_i}{\sum_{i \in G} y_i}$$

Donde:

- y: Etiqueta real (1 si enfermo, 0 si sano).
- p: Probabilidad calculada por el modelo.
- G: Subgrupo analizado.

Estas cuatro métricas se calcularán sobre el conjunto de prueba de cada uno de los 5 pliegues de la validación cruzada, y se reportará el promedio y la variación entre pliegues para tener una idea de qué tan estables son los resultados.

V. ANÁLISIS TÉCNICO

V-A. Análisis Exploratorio de Datos

El dataset consta de 457,670 registros y 33 columnas. La variable objetivo (riesgo cardiovascular) se construye como la unión lógica de CVDINFR4, CVDCRHD4 y CVDSTRK3, excluyendo previamente los 7,910 registros (1.73 % del total) con al menos un valor faltante en estas tres columnas, en lugar de tratar dichos valores como ausencia de riesgo. Sobre los 449,760 registros válidos, el desbalance resultante es de 88.18 % sin riesgo frente a 11.82 % con riesgo, consistente con lo reportado en la Sección IV-D. Al desagregar por grupo demográfico, la disparidad más marcada no aparece por sexo (13.57 % en hombres vs. 10.24 % en mujeres) ni por raza (entre 4.39 % y 14.05 % según grupo), sino por nivel de ingreso: aplicando el mismo criterio de exclusión, la prevalencia de riesgo desciende de forma prácticamente monotónica desde 19.87 % en la categoría de ingreso de \$15,000–\$24,999 hasta

5.51 % en el grupo de mayores ingresos ($\geq \$200,000$), con la categoría de menor ingreso ($< \$15,000$) en 18.64 %. Este gradiente socioeconómico, más pronunciado que las brechas de sexo o raza, respalda incluir `_INCOMG1` como atributo sensible adicional en el análisis de equidad.

V-B. Diccionario de Datos

Las 33 variables del dataset se agrupan en cinco categorías: demografía y variables socioeconómicas (14 variables), antropometría (3), antecedentes cardiovasculares y comorbilidades (9), estilo de vida (4), y salud percibida (3). El detalle de cada variable, su definición y codificación de valores se documenta en el diccionario de datos del repositorio (`Dataset/diccionario_datos.md`). Las variables protegidas para el análisis de equidad son `_SEX`, `_RACE` e `_INCOMG1`.

V-C. Calidad de Datos

29 de las 33 columnas presentan al menos un valor faltante, únicamente 4 columnas están completas. El diagrama siguiente resume las variables con mayor proporción de valores faltantes sobre el total de 457,670 registros originales.




Figura 4. Porcentaje de valores faltantes por variable, sobre los 457,670 registros originales del dataset. `_INCOMG1` se resalta por concentrar la mayor proporción de datos faltantes (19.10 %), relevante para el análisis de equidad al ser uno de los atributos protegidos del estudio.

Adicionalmente, se identificó un problema de calidad de datos no documentado en el README original: 6 registros presentan valores de `HEIGHT3` superiores a 250 cm (máximo observado: 815 cm), fisiológicamente imposibles,

probablemente originados por un residuo de la conversión pies/pulgadas a centímetros del archivo fuente del CDC. Estos registros serán recodificados a valor faltante antes de la imputación, en lugar de tratarse como *outliers* estadísticos.

V-D. Imputación

Dado que `_INCOMG1` concentra la mayor proporción de valores faltantes (19.10 %) y que este patrón es un fenómeno documentado en encuestas de salud (asociado a la reticencia a reportar ingresos y no a un mecanismo aleatorio), la imputación proporcional se calculará de forma independiente dentro de cada pliegue de la validación cruzada, evitando que la distribución de ingresos del conjunto de prueba influya en la imputación del conjunto de entrenamiento. El 1.73 % de registros excluidos por valores faltantes en las columnas que definen la variable objetivo (Sección V-A) se descarta antes de la partición en pliegues, ya que no corresponde a una variable predictora imputable sino a la ausencia de una etiqueta confiable.

V-E. Outliers

Se aplicó el método de rango intercuartílico (IQR, $k = 1.5$) sobre las variables continuas. Para `_BMI5` (3.15 % de outliers), `WEIGHT2` (1.72 %) y `HEIGHT3` (0.43 %, excluyendo los 6 valores imposibles ya descritos), el método identifica casos plausibles de obesidad severa o baja estatura, que se conservan por representar variabilidad real de la población. Para `PHYSHLTH`, `MENTHLTH` y `_DRNKWK3`, en cambio, el método IQR marca entre 13.90 % y 14.81 % de los registros como atípicos, un porcentaje excesivo que refleja la naturaleza de estas variables (distribución muy concentrada en cero, con un rango acotado por diseño de 0 a 30 días), por lo que el criterio IQR no es apropiado aquí, se conserva el rango completo definido por el diseño de la encuesta.

V-F. Desbalance de Clases

Además del desbalance global (88.18 %/11.82 %) y su variación por sexo y raza (Sección IV-D), el gradiente por ingreso descrito en la Sección V-A (19.87 % a 5.51 %) motiva evaluar las métricas de equidad no solo entre grupos de sexo y raza, sino también entre categorías de ingreso de `_INCOMG1`, ampliando el alcance del análisis de disparidad planteado originalmente en la Sección IV.

V-G. Prevención de Data Leakage

Las tres variables que componen la etiqueta objetivo (CVDINFR4, CVDCRHD4, CVDSTRK3) se excluyen explícitamente del conjunto de variables predictoras. Ninguna otra variable del dataset se deriva matemáticamente del objetivo, aunque GENHLTH y DIABETE4 están correlacionadas clínicamente con el riesgo cardiovascular sin ser una redefinición del mismo, por lo que se conservan como predictores legítimos. Como se describe en la Sección IV-C, la imputación, normalización y balanceo con SMOTE se ajustan de forma independiente dentro de cada pliegue de validación cruzada, usando únicamente los datos de entrenamiento de ese pliegue.

VI. CONSIDERACIONES ÉTICAS PRELIMINARES

Como se evidencia a lo largo de este trabajo, hay un gran riesgo de sesgo a la hora de determinar el rendimiento de los modelos. Este estudio intenta reducir el desbalance de datos con técnicas de imputación proporcional o SMOTE, y así obtener resultados que ilustren la posible discriminación hacia ciertos grupos con datos equitativos. La información del dataset crudo demuestra que hay 13.57 % de hombres que sufren CVD y 10.24 % mujeres. Además, varía entre grupos raciales, entre 4.39 % y 14.05 % según el grupo. Por lo tanto, el riesgo de sesgos es alto, en especial por el volumen de datos con el que se estará trabajando.

Un posible problema a la hora de reducir el sesgo es la inclusión de los atributos protegidos en el entrenamiento [1]. Esto podría generar parcialidad por el agente, en cambio, no agregar las columnas sobre raza y sexo resultaría beneficioso para que el algoritmo no detecte diferencias entre las poblaciones. Aún así, Farquhar [17] explica la posibilidad de que factores incluidos en el dataset de BRFSS como índice de pobreza, nivel de acceso a servicios médicos o ubicación geográfica amplíen la disparidad incluso cuando no están los grupos demográficos presentes explícitamente.

También, Sheetal et al. [20] sugieren limitaciones con el uso de SMOTE, específicamente, cuando esta es la única técnica implementada. Dicta que un único acercamiento a la corrección de desbalance podría resultar en dificultades para detectar enfermedades cardiovasculares sobre las clases minoritarias. Para corregirlo, indica que es necesario algún método adicional como *oversampling*, *undersampling*, *class weight* u otro, dependiendo de las propiedades del dataset.

Otro riesgo a tener en cuenta es la calidad de información recopilada por BRFSS en 2024 y cómo esta puede estar

siendo afectada por factores como los cambios de hábito post-pandemia. Características como el grado de aislamiento, frecuencia de actividad física o acceso a salud puede estar distorsionado por el momento en qué se obtuvo esta información. Esto impacta los resultados que brinden los agentes sobre la conducta de ciertos grupos demográficos y las conclusiones podrían volverse obsoletas con un dataset más actual.

Las dificultades anteriores han sido contempladas a lo largo de este estado del arte, y, a pesar de los riesgos que conlleva, se implementará resampling con SMOTE para el balanceo de datos. Aunque algunos artículos critican su eficiencia o su confiabilidad, se ha concluido que es el mejor método para evitar el desbalance de un dataset. Esto aborda las dos primeras problemáticas descritas. De esta forma, para asegurar la vigencia de los datos en el futuro sería necesario una comparación con un nuevo dataset más reciente, lo cual, no está en el alcance de esta investigación, pero se mantiene como una de sus limitaciones.

VII. DECLARACIÓN DE USO DE IA

El equipo utilizó un asistente de inteligencia artificial (LLM) como apoyo en tareas puntuales, nunca como sustituto de la investigación ni de las decisiones técnicas del proyecto. Concretamente, se usó para: dar formato al documento en LaTeX y depurar errores de compilación (estructura de tablas y figuras, referencias cruzadas), generar el código en Python de las figuras descriptivas a partir de datos ya calculados por el equipo (pipeline de preprocesamiento, distribución del riesgo por grupo demográfico, porcentaje de valores faltantes) y revisar la redacción de algunas secciones para mejorar claridad y consistencia con el resto del documento.

La búsqueda, lectura y selección de la literatura citada, las decisiones de diseño metodológico y la interpretación de los resultados fueron realizadas por los autores. Todo contenido generado o sugerido por la herramienta fue revisado y verificado manualmente por al menos un integrante del equipo antes de incorporarse al documento final.

REFERENCIAS

- [1] F. Li, P. Wu, H. H. Ong, J. F. Peterson, W.-Q. Wei, and J. Zhao, "Evaluating and mitigating bias in machine learning models for cardiovascular disease prediction," *J Biomed Inform*, vol. 138, p. 104294, Feb. 2023.
- [2] J. Zhang and Z.-m. Zhang, "Ethics and governance of trustworthy medical artificial intelligence," *BMC Med Inform Decis Mak*, vol. 23, p. 7, Jan. 2023.
- [3] J. K. Obra, C. Singh, K. Watkins, J. Feng, Z. Obermeyer, and A. Kornblith, "Potential for algorithmic bias in clinical decision instrument development," *NPJ Digit Med*, vol. 8, p. 762, Dec. 2025.

- [4] R. Abulibdeh, Y. Lin, S. Ahmadi, E. Sejdić, L. A. Celi, Q. Zhao, and K. Tu, "Integration of fairness-awareness into clinical language processing models," *Commun Med*, vol. 6, p. 178, Feb. 2026.
- [5] J. Hourmozdi, N. Easton, S. Benigeri, J. D. Thomas, A. Narang, D. Ouyang, G. Duffy, R. Upton, W. Hawkes, A. Akerman, I. Okwuosa, A. Kline, A. N. Kho, Y. Luo, S. J. Shah, and F. S. Ahmad, "Evaluating the performance and potential bias of predictive models for detection of transthyretin cardiac amyloidosis," *JACC Adv*, vol. 4, no. 8, p. 101901, Jul. 2025.
- [6] R. Agarwal, M. Bjarnadottir, L. Rhue, M. Dugas, K. Crowley, J. Clark, and G. Gao, "Addressing algorithmic bias and the perpetuation of health inequities: an ai bias aware framework," *Health Policy Technol*, vol. 12, no. 1, p. 100702, 2023.
- [7] J. Huang, G. Galal, M. Etemadi, and M. Vaidyanathan, "Evaluation and mitigation of racial bias in clinical machine learning models: scoping review," *JMIR Med Inform*, vol. 10, no. 5, p. e36388, May 2022.
- [8] M. Adouani, D. Annane, and Z. Chelly Dagdia, "Rethinking fairness in unsupervised healthcare ai: a methodological scoping review," *J Biomed Inform*, vol. 179, p. 105040, Jul. 2026.
- [9] A. Davoudi *et al.*, "Fairness gaps in machine learning models for hospitalization and emergency department visit risk prediction in home healthcare patients with heart failure," *International Journal of Medical Informatics*, vol. 191, p. 105534, Jun. 2024.
- [10] A. Foryciarz, S. R. Pfohl, B. Patel, and N. Shah, "Evaluating algorithmic fairness in the presence of clinical guidelines: the case of atherosclerotic cardiovascular disease risk estimation," *BMJ Health Care Inform*, vol. 29, no. 1, Apr. 2022.
- [11] S.-Y. Cho *et al.*, "Pre-existing and machine learning-based models for cardiovascular risk prediction," *Sci Rep*, vol. 11, no. 1, p. 8886, Apr. 2021.
- [12] S. R. Pfohl, A. Foryciarz, and N. H. Shah, "An empirical characterization of fair machine learning for clinical risk prediction," *J Biomed Inform*, vol. 113, p. 103621, Jan. 2021.
- [13] S. R. Pfohl, H. Zhang, Y. Xu, A. Foryciarz, M. Ghassemi, and N. H. Shah, "A comparison of approaches to improve worst-case predictive model performance over patient subpopulations," *Sci Rep*, vol. 12, no. 1, p. 3254, Feb. 2022.
- [14] J. T. Lee *et al.*, "Evaluating algorithmic fairness of machine learning models in predicting underweight, overweight, and adiposity across socioeconomic and caste groups in india: evidence from the longitudinal ageing study in india," *PLOS Digital Health*, vol. 4, no. 11, pp. 1–16, Nov. 2025.
- [15] M. Imani, A. Maroosi, S. Shojaei, K. Heidari, S. M. Hoseinzadeh, N. Daneshi, Z. Saber, N. Sajadi, and M. Mohammadzadeh, "Predicting cardiovascular diseases using imbalanced data: An xgboost-based analysis of the 2022 brfss dataset," *American Heart Journal Plus: Cardiology Research and Practice*, p. 100719, 2026.
- [16] J. Islam, D. Datta, and F. Akhter, "Leakage-safe precision-aware dual-branch ft-transformer for population-scale heart disease risk prediction," *Sensors*, vol. 26, no. 11, p. 3417, 2026.
- [17] H. Farquhar, "Persistent proxy discrimination in hiv testing prediction models: A national fairness audit of 386,775 us adults," *medRxiv*, pp. 2026–01, 2026.
- [18] E. Dritsas and M. Trigka, "Efficient data-driven machine learning models for cardiovascular diseases risk prediction," *Sensors*, vol. 23, no. 3, p. 1161, 2023.
- [19] K. Sathyaseelan and S. Sarathambekai, "A comparative analysis of ensemble techniques and hyperparameter tuning for enhanced heart disease prediction," in *2025 International Conference on Next Generation Computing Systems (ICNGCS)*. IEEE, 2025, pp. 1–8.
- [20] Sheetal, S. S. Deora, I. U. Haq, S. Z. Rufai, and A. Kumar, "Evaluating machine learning models for cardiovascular disease prediction: balancing accuracy and minority class detection," *Archives of Computational Methods in Engineering*, vol. 33, no. 2, pp. 2451–2469, 2026.
- [21] Y. Wang, E. Aivalioti, K. Stamatelopoulous, G. Zervas, M. B. Mortensen, M. Zeller, L. Liberale, D. Di Vece, V. Schweiger, G. G. Camici *et al.*, "Machine learning in cardiovascular risk assessment: towards a precision medicine approach," *European Journal of Clinical Investigation*, vol. 55, p. e70017, 2025.
- [22] T. Liu, A. Krentz, L. Lu, and V. Curcin, "Machine learning based prediction models for cardiovascular disease risk using electronic health records data: systematic review and meta-analysis," *European Heart Journal-Digital Health*, vol. 6, no. 1, pp. 7–22, 2025.
- [23] Y. Z. Rawash, H.-N. Ting, and K. H. Chee, "Study on basic machine learning techniques to detect and classify cardiovascular diseases," *REVISTA INTERNACIONAL DE METODOS NUMERICOS PARA CALCULO Y DISEÑO EN INGENIERIA*, vol. 42, no. 3, 2026.